1BP443 – Semestrální práce

DETEKCE FRAUDU V POJIŠŤOVACÍCH ŠKODÁCH

Binární klasifikátor pro detekci fraudu ve škodních událostech s interpretací

David Bárta
Daniel Petr Jašek
Veronika Nozdrenkova

Představení datasetu

Dataset obsahuje záznamy o pojistných událostech (dopravní nehody) z nichž některé jsou označené jako podvody:

- 33 sloupců a 15 420 řádků
- Cílový atribut je `FraudFound_P` (binární proměnná)

Řada proměnných, které popisují různé aspekty dané pojistné události:

- **Čas** - proměnné týkající se dne/týdne/měsíce, kdy došlo k nehodě a dále kdy byla nahlášena
- **Údaje o vozidle** - značka, kategorie, cena, stáří,...
- **Údaje o pojištěnci** - pohlaví, věk,...
- **Detaily pojistné smlouvy** - typ, spoluúčast, doba uzavření před nehodou,...
- **Detaily konkrétní nehody** - viník, svědek, oblast,...

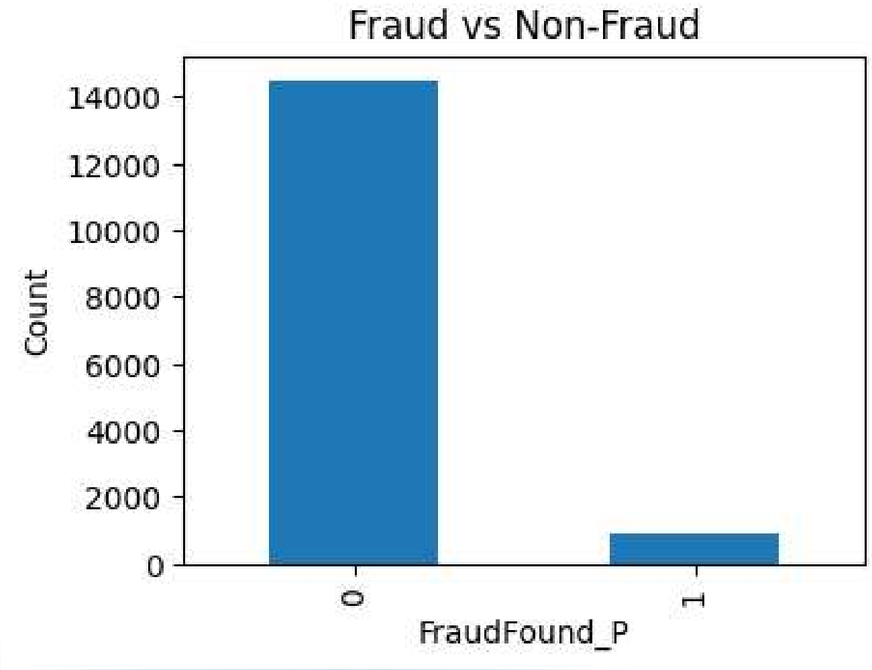

Vybrané hodnoty proměnných:

- `FraudFound_P` – přítomnost podvodu v dané události (6%)
- `Age` - průměrný věk podvodných klientů je 38,3 let
- `Make` - nejvíce podvodů u vozů Pontiac, Toyota a Honda (62,6%)

Data Preprocessing

- Odstranění technických a málo přínosných sloupců pro zpřehlednění datasetu a zvýšení výkonu modelu, např. `PolicyNumber`, `RepNumber`.

- Úprava původního pole `PolicyType`
  `PolicyType` kombinoval dvě různé informace → byl málo interpretovatelný pro model.
  Byl rozdělen na:
  - `VehicleCategory` — typ vozidla (Sedan, Utility, Sports Car…)
  - `BasePolicy` — typ pojistného krytí (Liability, Collision, All Perils…)

PolicyType	VehicleCategory	BasePolicy
Sedan - Collision	Sedan	Collision
Sedan - Collision	Sedan	Collision
Sedan - All Perils	Sedan	All Perils
Sedan - Collision	Sedan	Collision

Data Preprocessing

- One-hot encoding kategoriálních proměnných

  Převedeny byly klíčové kategorické údaje: `Sex` `MaritalStatus` `AccidentArea` `Fault` `AgentType` `WitnessPresent` `PoliceReportFiled`

  → jasné oddělení kategorií
  → lepší schopnost modelu učit se diskrétní rozdíly

- Vytvoření nového časového prediktoru

  `WeeksIncidentToClaim` = rozdíl mezi datem incidentu a datem nahlášení škody

Data Preprocessing

- Úprava proměnné `Make` (značka vozidla)
  - dataset obsahoval desítky značek aut, mnohé velmi vzácné
  - ponechány byly top 10 nejčastějších značek
  - všechny ostatní byly sloučeny do skupiny "Other"

Make	count
	None Count 0 (1 – 3837)
Pontiac	3837
Toyota	3121
Honda	2801
Mazda	2354
Chevrolet	1681
Accura	472
Ford	450
VW	283
Dodge	109
Saab	108
Mercury	83
Saturn	58
Nisson	30
BMW	15
Jaguar	6
Porche	5
Mecedes	4
Ferrari	2
Lexus	1

Make	count
	None Count 0 (108 – 3837)
Pontiac	3837
Toyota	3121
Honda	2801
Mazda	2354
Chevrolet	1681
Accura	472
Ford	450
VW	283
Other	204
Dodge	109
Saab	108

Data Preprocessing

Numerical binning

Použit u proměnných, které mají jasný business význam

`Age` převedeno do věkových skupin (např. <25, 25–40, 40–60, 60+)

`Deductible` rozděleno na low / medium / high

Deductible	count
	None Count 0
Medium	14838
High	574
Low	8

Age	
None Count	0
Age_1	22.1%
Age_0	21%
Other	56.9%
Age_0	
Age_1	
Age_3	
Age_4	
Age_0	
Age_0	
Age_2	

Modely - řešení nevyváženosti

Dataset měl výrazně méně fraudů než nefroudů → imbalance problem.

Použili jsme class weights:

- větší váha na pozitivní třídu `FraudFound_P = 1`
- model je penalizován za chybnou predikci fraudu → učí se více zaměřit na vzácné případy

Proč ne SMOTE?

- generoval nereálné syntetické vzorky
- XGBoost s class weights měl stabilnější výkon

Výhoda:
lepší recall bez extrémního nárůstu false positives.

Modely

Testované Modely:
LogReg, Random Forest, XGBoost

Finální model:
XGBoost (workload 25 %, threshold ≈ 0.54)
→ nejlepší recall
→ dobrý kompromis FP vs FN

	model	max_pos_rate_req	threshold	recall_test	precision_test	f1_test	auc_test	positive_rate_test	TP	FP	FN	TN
0	LogReg	0.20	0.69	0.467391	0.154955	0.232747	0.797282	0.179961	86	469	98	2431
1	LogReg	0.25	0.65	0.597826	0.143979	0.232068	0.797282	0.247730	110	654	74	2246
2	LogReg	0.30	0.62	0.663043	0.136618	0.226555	0.797282	0.289559	122	771	62	2129
3	RF	0.20	0.28	0.478261	0.152249	0.230971	0.800316	0.187419	88	490	96	2410
4	RF	0.25	0.25	0.581522	0.145777	0.233115	0.800316	0.238003	107	627	77	2273
5	RF	0.30	0.22	0.684783	0.139535	0.231831	0.800316	0.292802	126	777	58	2123
6	XGB	0.20	0.61	0.494565	0.155290	0.236364	0.802675	0.190013	91	495	93	2405
7	XGB	0.25	0.54	0.625000	0.145939	0.236626	0.802675	0.255512	115	673	69	2227
8	XGB	0.30	0.48	0.679348	0.137061	0.228102	0.802675	0.295720	125	787	59	2113

Workload-based threshold

- Second-Line tým má omezenou kapacitu.
- Threshold tedy nastavujeme tak, aby model označil ~25 % škod.
  → **optimální threshold: 0.54**

Výsledek při thresholdu 0.54

- Recall = 0.625 – zachytíme nejvíce možných fraudů
- Precision ≈ 0.146 – přijatelný počet falešných označení
- TP = 115, FN = 69
- nejlepší kompromis FP vs FN při stejné zátěži týmu

Trade-off

- nižší threshold → více zachycených fraudů, ale více FP
- vyšší threshold → méně FP, ale uniknou drahé fraudy

Interpretace výsledků vybraného modelu 1

Model: XGBoost, 25% workload, 0,54 threshold

Základní statistiky:

- TN = 2227 - model správě vyhodnotil, že tyto instance nejsou podvodné
- FN = 69 - model nezachytil podvod
- FP = 673 - falešné poplachy
- TP = 115 - správně odhalené podvody

Recall: 62,5% - kolik skutečných podvodů model zachytil
Precision: 14,6% - poměr správně odhalených podvodů ke všem případům, které model označil jako pozitivní
Accuracy: 76% - celková správnost

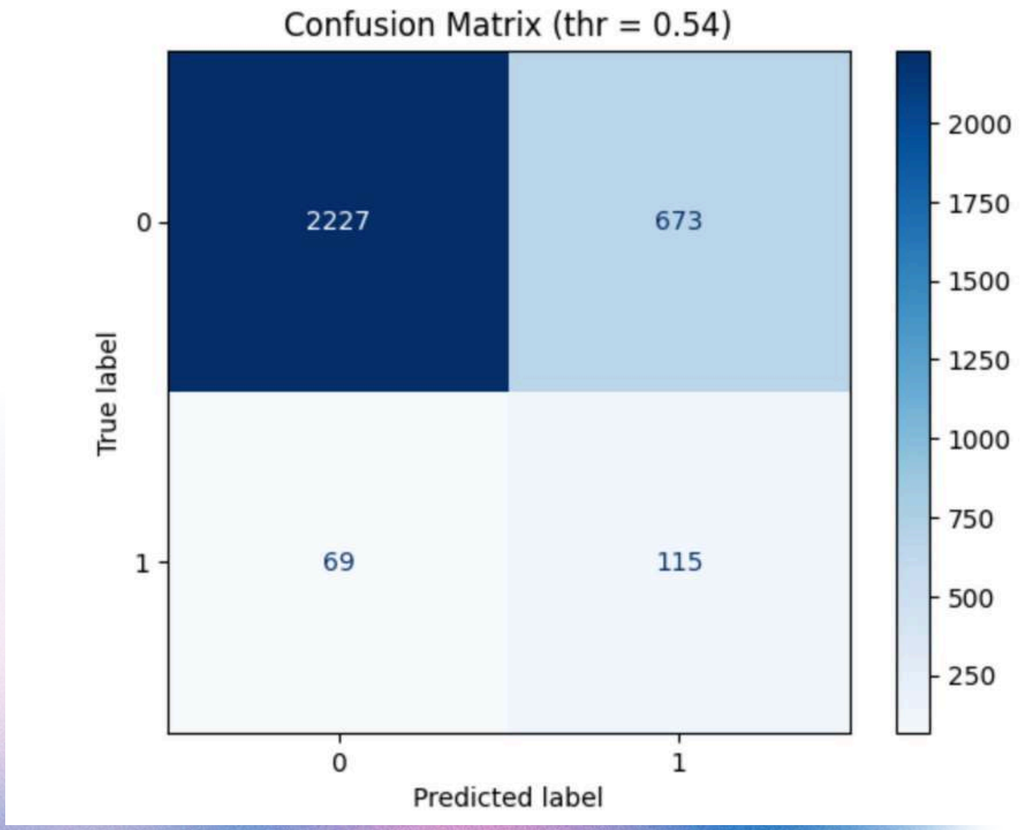

Interpretace výsledků vybraného modelu 2

SHAP

- je-li hodnota větší než 1, zvyšuje tento atribut pravděpodobnost podvodu
- je-li hodnota atributu menší než 1, naopak atribut pravděpodobnost snižuje
- slouží k identifikaci red flags
- vyjadřuje příspěvek jednotlivých atributů k výsledné predikci

3 nejvýznamnější red flags

- Zavinění třetí stranou
- Pouze povinné ručení
- Počet týdnů mezi nehodou a nahlášením

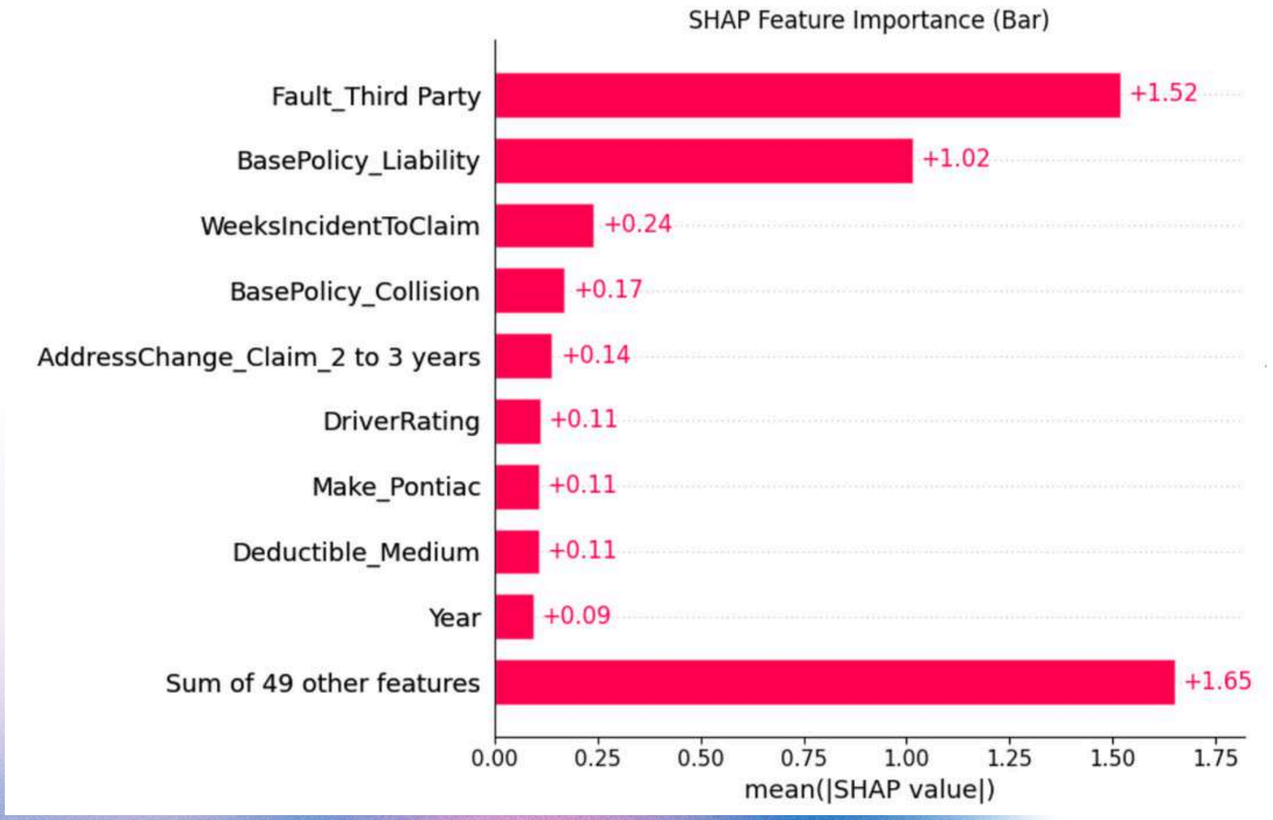

Interpretace výsledků vybraného modelu 3

Interpretace red flags - beeswarm

- Zavinění třetí stranou - v případě, že nehodu zavinil sám pojistník, jedná se o varovný signál
- Pouze povinné ručení - klienti bez doplňkového pojištění (havarijní,...) jsou podezřelejší
- Doba mezi nehodou a nahlášním - čím delší prodleva, tím větší pravděpodobnost podvodu

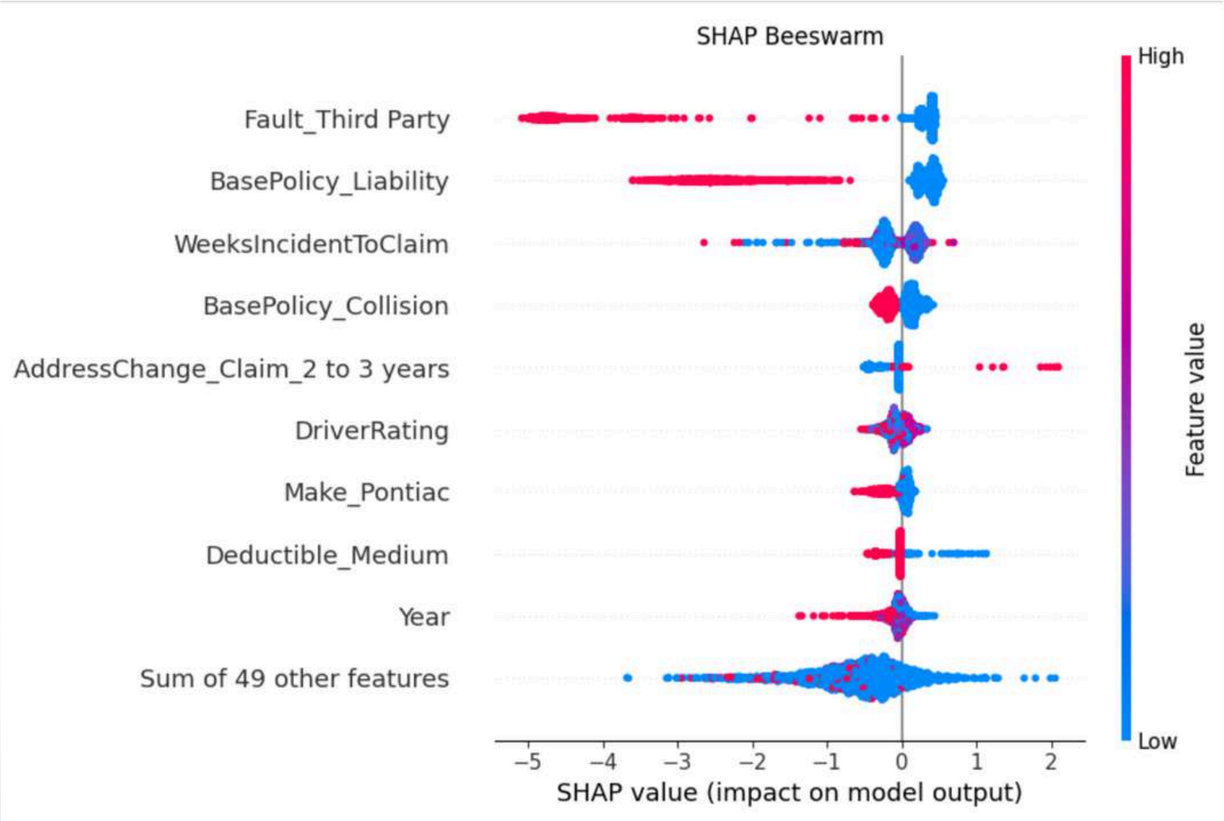

Interpretace výsledků vybraného modelu 4

ROC Curve

- AUC = 0,812 - křivka je nad diagonálou, takže model je lepší, než random guessing
- Pravděpodobnost, že model správně vyhodnotí jednotlivou událost je 81,2 %
- Tato hodnota značí dobrý model, který netrpí na overfitting

Precision-Recall Curve

- AP = 0,241 - zobrazuje vztah mezi “chycením” podvodu (Recall) a přesností výběru (Precision)
- Pro zachycení více podvodů musíme obětovat přesnost
- Realita u nevyvážených datasetů

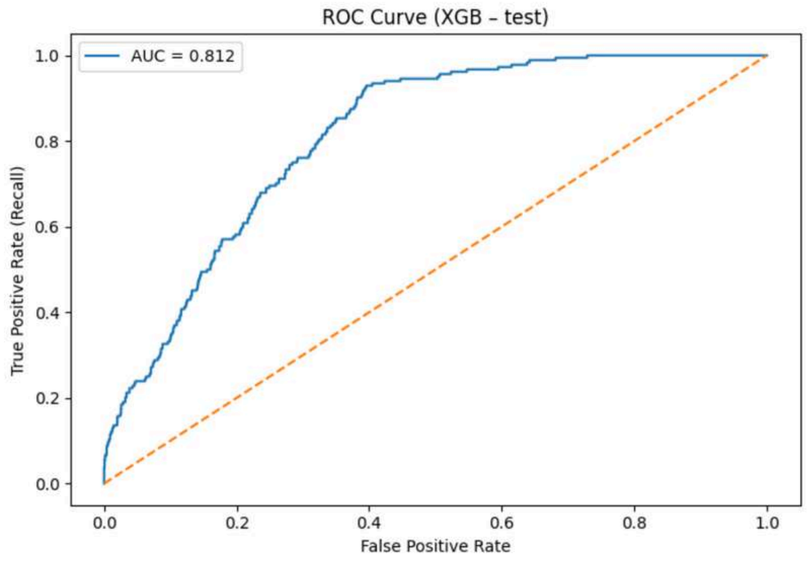

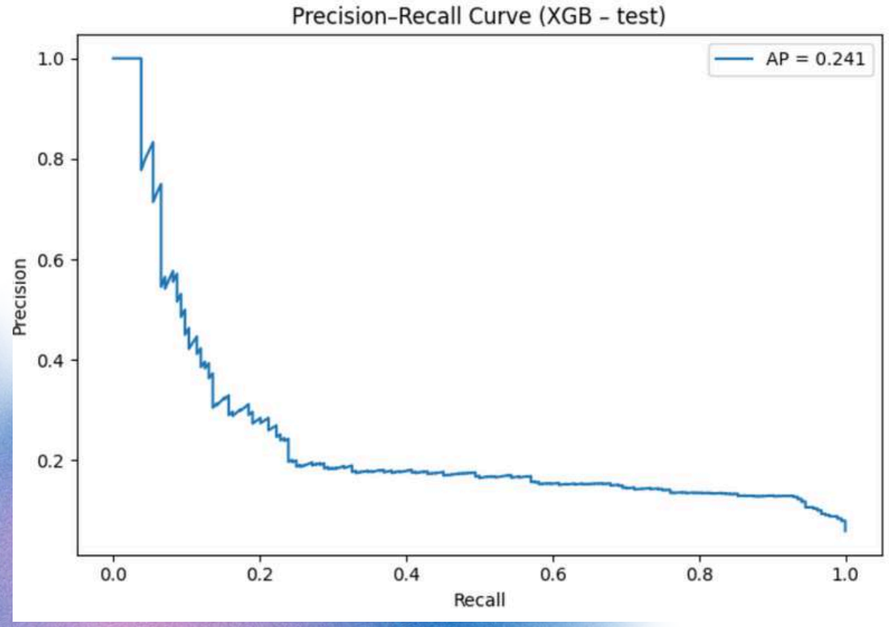

Ekonomické parametry pojistného trhu v ČR

Výše pojistného podvodu

- Dle České asociace pojišťoven (ČAP) je průměrná výše odhaleného pojistného podvodu v ČR **266 600 Kč**
- Používáme celkem 4 scénáře

Scénář	Výše odhaleného podvodu
Konzervativní	100 000 Kč
Realistický	250 000 Kč
ČAP	266 600 Kč
Optimistický	300 000 Kč

Náklady na second-line review (SLR)

- Přímé a nepřímé náklady: mzda, odvody zaměstnavatele, časová dotace na jeden review
- Role: claims examiner / claims analyst, fraud investigator, senior fraud analyst
- Celkový počet review dle modelu: **788**
- Cena jednoho review: **900 – 1500 Kč**

Počet reviews	Náklady na 1 review	Celkové náklady na SLR
788	900 Kč	709 200 Kč
788	1 200 Kč	945 600 Kč
788	1 500 Kč	1 182 000 Kč

Hrubá úspora

- Částka, kterou pojišťovna ušetří díky odhalení nebo prevenci pojistných podvodů

$$H = TP * V$$

- H = hrubá úspora
- TP = počet zachycených podvodů = 115
- V = průměrná výše podvodu

Tabulka hrubých úspor:

Scénář	Průměrná výše podvodu	**Hrubá úspora**
Konzervativní	100 000 Kč	**11 500 000 Kč**
Realistický	250 000 Kč	**28 750 000 Kč**
ČAP	266 600 Kč	**30 659 000 Kč**
Optimistický	300 000 Kč	**34 500 000 Kč**

Čistá úspora

- Celková částka, kterou pojišťovna ušetří díky odhalení nebo prevenci pojistných podvodů, po odečtení všech nákladů spojených s odhalelím a řešením podvodů

$$C = H - N$$

- C = čistá úspora
- H = hrubá úspora
- N = náklady na SLR (SLR = 788)

Tabulka čistých úspor (v Kč) - vybrané scénáře:

Průměrná výše podvodu	Náklady na 1 review	Hrubá úspora	Náklady SLR	**Čistá úspora**
100 000	1 500	11 500 000	1 182 000	**10 318 000**
250 000	1 200	28 750 000	945 600	**27 804 400**
266 600	1 200	30 659 000	945 600	**29 713 400**
300 000	900	34 500 000	709 200	**33 790 800**

Čistá úspora

Tabulka čistých úspor (v Kč) - všechny scénáře:

Výše odhaleného podvodu	Náklady na 1 review	Hrubá úspora	Náklady SLR	**Čistá úspora**
100 000	900	11 500 000	709 200	**10 790 800**
100 000	1 200	11 500 000	945 600	**10 554 400**
100 000	1 500	11 500 000	1 182 000	**10 318 000**
250 000	900	28 750 000	709 200	**28 040 800**
250 000	1 200	28 750 000	945 600	**27 804 400**
250 000	1 500	28 750 000	1 182 000	**27 568 000**
266 600	900	30 659 000	709 200	**29 949 800**
266 600	1 200	30 659 000	945 600	**29 713 400**
266 600	1 500	30 659 000	1 182 000	**29 477 000**
300 000	900	34 500 000	709 200	**33 790 800**
300 000	1 200	34 500 000	945 600	**33 554 400**
300 000	1 500	34 500 000	1 182 000	**33 318 000**

Závěr

1. Model má dobrou schopnost rozlišovat rizikové události, i když jsou fraudy vzácné
2. Model je lepší než náhodné třídění i při nízké prevalenci fraudů, ale vždy bude existovat kompromis mezi zachycením podvodů a počtem falešně označených případů.
3. Threshold 0.54 je optimální, protože maximalizuje počet odhalených fraudů bez toho, aby zahltil tým second-line review.
4. I s neideální precision je model extrémně výhodný — falešné případy stojí tisíce korun, ale jeden zachycený fraud šetří statisíce.

Zdroje

1. Česká asociace pojišťoven

Česká asociace pojišťoven. *Pojistný podvod se Čechům příčí. Počet podezřelých pojistných událostí přesto i v roce 2023 rostl* [online]. 2024 [cit. 2025-09-12].
Dostupné z: https://www.cap.cz/tiskove-centrum/tiskove-zpravy/9224645-pojistny-podvod-se-cechum-prici-pocet-podezrelych-pojistnych-udalosti-presto-i-v-roce-2023-rostl

2. GENERALI Česká pojišťovna

GENERALI Česká pojišťovna. *Statistika odhalených pojistných podvodů za rok 2024: Uchraněná hodnota atakovala sumu 700 milionů korun* [online]. 2024 [cit. 2025-09-12].
Dostupné z: https://www.generaliceska.cz/-/statistika-odhalenych-pojistnych-podvodu-za-rok-2024-uchranena-hodnota-atakovala-sumu-700-milionu-korun

3. PEXELS

PEXELS. *Pexels – Free Stock Photos* [online]. 2025 [cit. 2025-09-12].
Dostupné z: https://www.pexels.com/

4. SHIVAM (Kaggle)

SHIVAM. *Vehicle Claim Fraud Detection* [online]. Kaggle, 2019 [cit. 2025-09-12].
Dostupné z: https://www.kaggle.com/datasets/shivamb/vehicle-claim-fraud-detection